

Reinforcement Learning for Bipedal Locomotion Using Minimal Instrumentation with a Single Inertial Measurement Unit

1st Juan Esteban Gomez Lopez
Semillero SAE, Universidad Santiago de Cali
Universidad Santiago de Cali
Cali, Colombia
juan.gomez44@usc.edu.co

2nd Yesid Eugenio Santafe Ramon
Semillero SAE, Universidad Santiago de Cali
Universidad Santiago de Cali
Cali, Colombia
yesid.santafe00@usc.edu.co

Abstract—This work presents a simulation-based validation framework for locomotion control on a custom-built 13 DoF bipedal robot using only signals derivable from a 6-axis inertial measurement unit (3D angular velocity and 3D gravity vector projection) as actor observations. The system employs the Genesis World simulator and the rsl-rl-lib library with PPO and a privileged critic architecture, where the actor only accesses IMU signals, reference speed commands, and past actions, without joint encoders or additional exteroceptive sensors. Training converges in 4,000 iterations (393M environment steps with 4,096 parallel environments): mean reward scales from 1.82 to 118.19, mean episode length goes from 22.8 to 1,007.6 steps, and success rate reaches 66.3%, with 99.8% vertical stability. The automatic curriculum unlocks running gait at iteration 126. This minimal instrumentation approach reduces hardware costs and facilitates replication in engineering laboratories with limited budgets.

Index Terms—Bipedal Robot, Minimal Observability, Reinforcement Learning, Locomotion, Sim-to-Real, Proximal Policy Optimization

I. INTRODUCCIÓN

La robótica bípeda requiere control dinámico complejo [1], [2]; las plataformas comerciales de referencia superan los 50kUSD [3], restringiendo su uso en laboratorios universitarios con presupuesto limitado.

Los simuladores modernos como Genesis World alcanzan 43M FPS en GPU [4], permitiendo entrenar políticas robustas en pocas horas [5]; sin embargo, la mayoría de trabajos asumen observaciones ricas (posición angular, cámaras y sensores de fuerza) [6] que encarecen la instrumentación del robot físico.

En este trabajo se aborda la locomoción bípeda con *observabilidad mínima en hardware*: la política del actor recibe únicamente velocidad angular e inclinación relativa medidas por una única IMU ensamblada en la cadera.

Prescindir de encoders articulares no es una simplificación trivial: elimina la retroalimentación que métodos como la cinemática inversa requieren para calcular trayectorias articulares. Sin esta información, la política debe reconstruir implícitamente el estado postural a partir de la historia de señales inerciales y comandos [7], [8].

Para ello se adopta una arquitectura de *critic privilegiado* [9], [10]: durante el entrenamiento, el critic recibe el estado completo del simulador, mientras que el actor solo accede a las señales disponibles en el robot real.

Las contribuciones de este trabajo son:

- Diseño y modelo MJCF de un robot bípido de 13 DoF propio ($\approx 1,18$ kg, 35,4 cm).
- Arquitectura sim-to-real con critic privilegiado para entrenar una política usando únicamente señales IMU, comandos de velocidad y acciones pasadas.
- Currículo automático de marchas walk→run basado en métricas de recompensa.
- Validación en simulación sobre 393 M pasos con métricas cuantitativas de estabilidad y seguimiento de velocidad.
- Framework replicable en laboratorios universitarios con infraestructura GPU estándar.

II. ESTADO DEL ARTE

Los trabajos de referencia en locomoción bípeda con aprendizaje por refuerzo operan típicamente sobre plataformas de masa considerable. Cassie [3], con aproximadamente 31 kg, reporta un 85 % de éxito utilizando un espacio de observación de 64 dimensiones para el actor. En contraste, el robot presentado en este trabajo mide 35,4 cm y pesa 1,18 kg, por lo que su inercia corporal mínima amplifica la sensibilidad a perturbaciones y vuelve la estabilidad más volátil que en plataformas de mayor masa. En cuanto a observabilidad sensorial, [7] demuestra locomoción bípeda basada en IMUs ubicadas en los pies. El presente trabajo incrementa la restricción al utilizar una única IMU ensamblada en la cadera y al prescindir también de sensores de fuerza en los pies, obligando a la política a inferir la fase de contacto exclusivamente a partir de la historia de señales inerciales y comandos.

Genesis Forge provee un *framework* de Optimización Proximal de Políticas (PPO) modular con alto rendimiento computacional [5], razón por la cual es adoptado en este trabajo. La arquitectura de critic privilegiado [9] ha demostrado ser

efectiva para reducir la brecha simulación-a-real (*sim-to-real*), permitiendo que el actor opere en hardware con observaciones restringidas.

Hasta donde conocen los autores, no existe trabajo previo que entrene locomoción bípeda en un robot propio de bajo costo, utilizando una única IMU de cadera, sin encoders articulares y sin sensores de fuerza en los pies, dentro del entorno Genesis World.

III. METODOLOGÍA

La Figura 1 ilustra el flujo de trabajo del marco propuesto, desde el diseño CAD hasta el despliegue de la política entrenada, detallando la interacción entre el actor, el *critic* y el entorno de simulación.




Figure 1: Diagrama de flujo del marco de entrenamiento propuesto, mostrando la arquitectura de critic privilegiado, la inyección de ruido y la evaluación del currículo.

A. Plataforma de Hardware y Software

Hardware de entrenamiento: Windows 11, GPU NVIDIA con soporte CUDA y 16 GB de memoria RAM. La disponibilidad de GPU es indispensable porque Genesis World paraleliza 4096 entornos de simulación directamente en el dispositivo gráfico.

Table I: Stack de software del framework.

Componente	Rol principal
Python 3.11	Lenguaje del framework
PyTorch 2.1	Backend de diferenciación automática
Genesis World	Simulador físico GPU (4096 entornos)
Genesis Forge	Abstracción del entorno y PPO modular [5]
rsl-rl-lib $\geq 2.2.4$	Runner on-policy, GAE y actualización PPO

B. Modelo del Robot


El robot bípedo cuenta con 13 grados de libertad (DoF) como se muestra en la Tabla II. La masa total es de $\approx 1,18$ kg, la altura en posición erguida es de $\approx 0,354$ m y la longitud de cada pierna es de $\approx 0,220$ m. Estas dimensiones implican una inercia corporal mínima por lo que una perturbación pequeña puede evolucionar rápidamente hacia una caída.

La Figura 2 presenta el modelo físico del robot importado en el simulador. Específicamente la Figura 2(a) ilustra la vista frontal detallando la distribución de los actuadores mientras que la Figura 2(b) muestra al robot ejecutando la pose de caminata (*walk*) adoptada durante el entrenamiento.

El modelo MJCF se generó automáticamente a partir del diseño CAD importado desde OnShape. El único sensor físico montado en el robot es una unidad de medición inercial (IMU) ubicada en la cadera.

Table II: Distribución de grados de libertad del robot.

Segmento	Articulaciones	DoF	Tipo
Brazo derecho	BD, HD	2	Hinge (1 eje)
Brazo izquierdo	HI, BI	2	Hinge (1 eje)
Pierna derecha	CD, LD, KD, FD	4	Hinge (1 eje)
Pierna izquierda	CI, LI, KI, FI	4	Hinge (1 eje)
Cabeza	HEAD	1	Hinge (Yaw)
Total		13	



(a) Vista frontal

(b) Pose walk

Figure 2: Robot bípedo de 13 DoF en Genesis World.

C. Arquitectura Sim-to-Real: Critic Privilegiado

Se adopta una arquitectura de *critic privilegiado*: durante el entrenamiento, el critic accede al estado completo del simulador (posición articular, velocidades, fuerzas de contacto y pose global), mientras que el actor recibe únicamente información disponible en el robot físico. En despliegue solo se ejecuta el actor, por lo que la función de valor no introduce dependencia de sensores adicionales [9].

D. Espacios de Observación

1) *Actor (grupo policy)*: El actor recibe para cada ventana temporal de 5 pasos observaciones compuestas por comando de velocidad, comando de marcha, velocidad angular, gravedad proyectada y acciones previas, como se muestra en la Ecuación (1):

$$\mathbf{o}_t^{\text{actor}} = \begin{bmatrix} \mathbf{v}^{\text{cmd}} \\ \mathbf{g}^{\text{gait}} \\ \boldsymbol{\omega}^{\text{IMU}} \\ \mathbf{g}_{\text{proj}}^{\text{IMU}} \\ \mathbf{a}_{t-1} \end{bmatrix} \in \mathbb{R}^{30}, \quad \mathbf{O}_t^{\text{actor}} \in \mathbb{R}^{150} \quad (1)$$

donde $\mathbf{v}^{\text{cmd}} \in \mathbb{R}^3$ es el comando de velocidad, $\mathbf{g}^{\text{gait}} \in \mathbb{R}^8$ agrupa el comando de marcha y las señales de reloj, $\boldsymbol{\omega}^{\text{IMU}} \in \mathbb{R}^3$ es la velocidad angular medida por la IMU, $\mathbf{g}_{\text{proj}}^{\text{IMU}} \in \mathbb{R}^3$ es el vector de gravedad proyectado derivado del acelerómetro y $\mathbf{a}_{t-1} \in \mathbb{R}^{13}$ son las acciones previas. Durante el entrenamiento, $\boldsymbol{\omega}^{\text{IMU}}$ y $\mathbf{g}_{\text{proj}}^{\text{IMU}}$ se corrompen con ruido gaussiano $\mathcal{N}(0, 0,05)$ para mejorar robustez sim-to-real.

Las señales de reloj, los comandos de marcha y las acciones previas no requieren sensado adicional; por tanto, el único sensor físico requerido en el robot real es la IMU.

2) *Critic (grupos policy + critic)*: El critic recibe adicionalmente, con la misma ventana de historia, la velocidad lineal y angular exactas del simulador, posición y velocidad articular de los 13 DoF, fuerzas articulares, posición y velocidad de pies, rodillas y tobillos, fuerzas de contacto, fase de marcha exacta, pose global, cuaternión del cuerpo y acciones actuales.

E. Aleatorización de Dominio e Inyección de Ruido

Para mejorar la robustez en el paso simulación-a-hardware real, en cada episodio se aplican perturbaciones aleatorias sobre parámetros físicos y señales sensoriales del actor.

Perturbaciones físicas: variación de masa $\pm 10\%$, variación de ganancias proporcional k_p y derivativa k_v de actuadores $\pm 10\%$, variación de amortiguamiento $\pm 25\%$ y de fricción $\pm 10\%$.

Ruido en señales del actor:

- Velocidad angular IMU $\boldsymbol{\omega}^{\text{IMU}}$ y gravedad proyectada $\mathbf{g}_{\text{proj}}^{\text{IMU}}$: ruido gaussiano $\mathcal{N}(0, 0,05)$ aplicado en cada paso de tiempo.
- Posición articular (solo en critic): $\sigma_\theta = 0,01$ rad.
- Velocidad articular: $\sigma_{\dot{\theta}} = 0,5$ rad/s.

La combinación de perturbaciones físicas y ruido sensorial evita sobreajuste a la simulación y favorece la transferencia posterior a hardware real.

F. Sistema de Recompensas

La recompensa total se define como una suma ponderada de términos de locomoción, estabilidad y eficiencia. Los términos y pesos se detallan en la Tabla III.

Los pesos extremos tienen justificación técnica: $r_{\text{air}} = +2,0$ incentiva la transición walk→run al premiar tiempo de vuelo

Table III: Función de recompensa: términos y pesos.

Término	Descripción	Peso
r_{alive}	Bono por paso sin caída	+1,0
r_{upright}	Estabilidad vertical	+1,5
r_{lin}	Seguimiento de velocidad lineal	+1,0
r_{ang}	Seguimiento de velocidad angular	+0,5
r_{gait}	Fase swing/stance por pie	+1,5
r_{fh}	Despeje del pie en swing	+0,9
r_{air}	Tiempo de vuelo (0,2–0,5 s)	+2,0
r_{alt}	Alternancia de pies	+0,5
p_{vz}	Oscilación vertical del torso	−0,5
$p_{\omega xy}$	Balaceo lateral/sagital	−0,05
p_{acc}	Aceleración brusca del cuerpo	−0,5
p_{height}	Desviación de altura objetivo	−5,0
p_{rate}	Variación brusca de acciones	−0,015
p_{dev}	Desviación de la pose por defecto	−0,05
p_{contact}	Contacto de rodillas/tobillos	−1,5
p_{fall}	Caída ($> 45^\circ$)	terminación

sostenido; $p_{\text{height}} = -5,0$ penaliza dominantemente cualquier colapso de la altura del torso.

G. Sistema de Marcha y Currículo

El módulo BipedGaitCommandManager gestiona dos marchas (Tabla IV) con fases swing/stance por pie, señales de reloj sinusoidales y muestreo curricular. El currículo se evalúa cada 50 iteraciones: si $\bar{r}_{\text{gait}} > 0,75$ se desbloquea la siguiente marcha; si $\bar{r}_{\text{fh}} > 0,80$ se amplía el rango de despeje del pie, evitando estrategias subóptimas como arrastre o salto simultáneo.

Table IV: Parámetros de marcha.

Marcha	Desfase L/R	Período (s)	Despeje (m)
walk	0,0/0,5	0,55–0,75	0,04–0,10
run	0,0/0,5	0,25–0,40	0,12–0,22

H. Hiperparámetros del Algoritmo PPO

La Tabla V resume los hiperparámetros del algoritmo PPO utilizado.

Table V: Hiperparámetros PPO.

Parámetro	Valor	Parámetro	Valor
Entornos	4 096	LR	10^{-4} (adapt.)
Pasos/env.	24	KL objetivo	0,01
Trans./iter.	98 304	γ	0,99
Épocas	5	λ_{GAE}	0,95
Mini-batches	4	Entropía	0,003
Actor MLP	[512,256,128]+ELU	ϵ clip	0,2
Critic MLP	[1024,512,256,128]+ELU	Frec. control	50 Hz

El actor π_θ y el critic privilegiado V_ϕ utilizan redes completamente conectadas con activación ELU y normalización de observaciones. La red del critic es mayor para representar la función de valor sobre el espacio de estado completo del simulador.

I. Implementación

El entorno hereda de `ManagedEnvironment` de `Genesis Forge` y delega la gestión de observaciones, recompensas, terminaciones y actuadores a gerentes especializados. El entrenamiento se ejecuta con `OnPolicyRunner` de `rsl-rl-lib`.

En cada iteración se recolectan 24 pasos por entorno sobre 4096 entornos paralelos. Las ventajas se estiman con GAE, como se muestra en la Ecuación (2):

$$A_t^{\text{GAE}(\lambda)} = \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l} \quad (2)$$

$$\delta_t = r_t + \gamma V_{\phi}(\mathbf{o}_{t+1}^{\text{critic}}) - V_{\phi}(\mathbf{o}_t^{\text{critic}})$$

Los parámetros se actualizan minimizando la pérdida clipada $L_{\text{clip}}(\pi_{\theta}, A_t)$. Cada 50 iteraciones se evalúa el currículo de marchas. Al finalizar las 4000 iteraciones, únicamente π_{θ} se despliega en hardware.

IV. RESULTADOS

A. Convergencia del Entrenamiento

El entrenamiento se ejecutó durante 4000 iteraciones, acumulando 393 M pasos en entornos, la Tabla VI resume las métricas globales. La Tabla VII reporta el error de seguimiento evaluado sobre un conjunto de 100 episodios independientes tras finalizar el entrenamiento, calculando el Error Absoluto Medio (MAE) y la Raíz del Error Cuadrático Medio (RMSE).

Table VI: Métricas de convergencia del entrenamiento.

Métrica	Valor final
Recompensa media	118,19
Recompensa pico	121,18
Longitud de episodio	1 007,6 pasos
Tasa de éxito	66,3 %
Tasa de caídas	33,7 %
Marcha <i>run</i> desbloqueada	iter. 126

Table VII: Error de seguimiento post-entrenamiento (1000 episodios).

Eje	Objetivo	Promedio	MAE	RMSE
Lineal	1,0 m/s	1,420 m/s	0,353 m/s	0,405 m/s
Angular	0,3 rad/s	0,339 rad/s	0,050 rad/s	0,062 rad/s

La curva de recompensa muestra fases claramente distinguibles. Durante las iteraciones 1–125, la política consolida la marcha *walk*; la recompensa supera 50 en la iteración 40 y la longitud de episodio supera 500 pasos en la iteración 39. En la iteración 126 se produce un incremento sostenido de la recompensa, coincidente con el desbloqueo de la marcha *run*. A partir de ese punto, la recompensa supera 100 en la iteración 303 y alcanza 118,19 al final del entrenamiento.

B. Análisis de Control: Seguimiento de Velocidad

1) *Seguimiento de Velocidad Lineal*: Evaluada en el conjunto de prueba independiente, la velocidad lineal promedio alcanzó 1,420 m/s para un objetivo constante de 1,0 m/s, resultando en un MAE de 0,353 m/s y un RMSE de 0,405 m/s. La estabilización en convergencia demuestra la capacidad del sistema para mantener un seguimiento continuo.

2) *Seguimiento de Velocidad Angular*: El seguimiento angular, con objetivo de 0,3 rad/s, mostró un desempeño más preciso: el promedio final fue 0,339 rad/s, con un MAE de 0,050 rad/s y un RMSE de 0,062 rad/s, confirmando un comportamiento predecible bajo el esquema de observación mínima..

C. Análisis por Componente de Recompensa

Los términos positivos dominantes al final del entrenamiento son la estabilidad vertical (1,497/1,5) y el seguimiento de velocidades. La recompensa de fase de marcha (0,918/1,0) indica coordinación swing/stance cercana al óptimo, mientras que la alternancia de pies converge a 0,434. Las penalizaciones permanecen pequeñas y estables, lo que sugiere una política suave y energéticamente eficiente.

D. Comparación con Métodos de Referencia

La Tabla VIII compara el enfoque propuesto con trabajos de referencia. Dado que se trata de plataformas diferentes, la comparación es cualitativa respecto a observabilidad del actor y restricciones de instrumentación.

La tasa de éxito del 66,3 % es inferior al 85,1 % reportado en *LeggedGym* [6]. Esta diferencia es consistente con la menor masa del robot, que lo hace más propenso a oscilaciones de alta frecuencia y más difícil de estabilizar sin retroalimentación de encoders.

Table VIII: Comparación cualitativa de enfoques.

Método	DoF	Obs. actor	Tasa éxito	Sensor requerido
Este trabajo	13	150D	66,3%	IMU cadera
<i>LeggedGym</i> [6]	28	64D	85,1%	enc.+IMU
IMU-feet [7]	12	48D	78,0%	2×IMU pie

E. Curvas de Entrenamiento




Figure 3: Recompensa media durante el entrenamiento. La recompensa aumenta de 1,82 a 118,19. La línea clara representa el valor bruto y la línea gruesa el valor suavizado.




Figure 4: Longitud del episodio durante el entrenamiento. El valor aumenta de 22,8 a 1007,6 pasos. La línea clara representa el valor bruto y la línea gruesa el valor suavizado.




Figure 5: Desviación estándar de la política PPO. El valor disminuye de 1,0 a 0,55 conforme avanza el entrenamiento. La línea clara representa el valor bruto y la línea gruesa el valor suavizado.

V. DISCUSIÓN

A. Eficiencia Computacional y Accesibilidad

Genesis World consiguió una velocidad promedio aproximada de $\approx 36k$ FPS con 4096 entornos paralelos en GPU. La eficiencia lograda permitió suministrar una cantidad de aproximadamente 393 M pasos del entorno en escaso tiempo usando un hardware de laboratorio, convirtiendo un problema computacionalmente exigente en uno que se puede gestionar de forma práctica dentro del alcance económico de ciertas instituciones.

B. Interpretación del Desempeño de Control

El error de seguimiento reportado debe considerarse en el marco de observación mínima. En ausencia de encoders articulares, la política debería estimar el estado postural y dinámico del robot desde datos de IMU con ruido. La reducción considerable del error en la convergencia indica una estabilidad bastante buena para futuras transferencias sim-to-real.

C. Validez de los Resultados y Limitaciones

Los resultados recogidos muestran una prueba de validez de alto grado simulando entornos reales. Aunque Genesis World proporciona modelos sólidos de contacto, fricción y dinámica, la diferencia entre simulación y realidad no ha sido completamente suprimida. Factores como el desgaste mecánico del sistema, la deformación estructural, el ruido del sensor IMU y la latencia en el feedback control siguen siendo desafíos inexplorados..

D. Validación del Currículo Automático

El desbloqueo de la marcha *run* en la iteración 126 demuestra que el currículo automático funcionó según su diseño: la política no intentó correr antes de consolidar un patrón de caminata estable. Esta propiedad es especialmente valiosa bajo observabilidad mínima, donde una transición prematura a la carrera aumentaría el riesgo de inestabilidad.

E. Análisis de Sensibilidad del Currículo Automático

Para validar el diseño del currículo se evaluaron configuraciones alternativas en el que un currículo *agresivo* (desbloqueo con $\bar{r}_{\text{gait}} > 0,50$) provocó que la política intentara correr de forma prematura dando como resultado inestabilidad y un aumento del 45 % en la tasa de caídas. Por el contrario un currículo del tipo *conservador* ($\bar{r}_{\text{gait}} > 0,90$) causó que la política se estancara en la marcha *walk*, incapaz de realizar la transición dentro del presupuesto de 4000 iteraciones. El umbral propuesto de 0,75 demostró ser el punto óptimo, permitiendo el desbloqueo exitoso en la iteración 126 sin sacrificar la estabilidad.

F. Generalización y Transferencia Sim-to-Real

Para probar la capacidad de generalización, la política final se sometió a un entorno de evaluación alternativo con parámetros no vistos durante el entrenamiento (fricción reducida, inyección de ruido de latencia). Aunque se observó una degradación en el seguimiento de la velocidad lineal, el robot mantuvo el equilibrio sin colapso de la política, sugiriendo que la aleatorización de dominio (*domain randomization*) incorporada proporciona una base robusta. No obstante, la validación definitiva de la arquitectura requerirá pruebas en hardware físico, abordando factores como el desgaste mecánico y la deformación estructural, que siguen siendo desafíos inexplorados en este trabajo.

VI. CONCLUSIONES

Este trabajo demuestra, mediante validación en simulación de alta fidelidad, que un robot bípedo propio de 13 DoF ($\approx 1,18$ kg y 35,4 cm de altura) puede aprender locomoción estable en 393 M pasos de simulación utilizando PPO con una arquitectura de critic privilegiado.

La política del actor opera con una única IMU montada en la cadera y sin encoders articulares, alcanzando una tasa de éxito del 66,3 %, estabilidad vertical de 1,497/1,5 y errores medios de seguimiento de 0,353 m/s en velocidad lineal y 0,050 rad/s en velocidad angular.

La alta eficiencia del simulador fue el factor habilitante del experimento en un laboratorio universitario sin infraestructura especializada. El enfoque de instrumentación mínima reduce el costo del robot físico y sienta bases para despliegues reales. El trabajo futuro prioritario contempla la transferencia sim-to-real al hardware físico y la exploración de arquitecturas con memoria recurrente para mejorar la inferencia del estado postural.

AGRADECIMIENTOS

Este trabajo tuvo desarrollo en el Laboratorio de Robótica y Visión de la Universidad Santiago de Cali, Cali, Valle del Cauca, Colombia, contando con acceso a los recursos computacionales de los laboratorios de la misma institución.

Los autores agradecen a la Dirección General de Investigaciones (DGI) de la Universidad Santiago de Cali por el apoyo financiero otorgado a través de la Convocatoria DGI-01-2026 y del proyecto 829-621123-246, que hizo posible la realización y presentación de este trabajo.

Se agradece también al Semillero de Investigación SAE y al Grupo de Investigación GIEIAM por el acompañamiento técnico y científico durante el desarrollo del proyecto, así como al apoyo brindado por los capítulos estudiantiles IEEE RAS y IEEE SPS de la Universidad Santiago de Cali (USC).

REFERENCES

- [1] L. Bao, J. Humphreys, T. Peng, and C. Zhou, “Deep reinforcement learning for robotic bipedal locomotion: A brief survey,” 2024.
- [2] W. Ridwan and M. F. Mysorewala, “Survey of bipedal robot control: A functional classification by control objectives,” *Journal of Robotics and Control*, Dec. 2025.
- [3] Agility Robotics, “Cassie biped specifications,” Agility Robotics Technical Report, 2023. [Online]. Available: <https://agilityrobotics.com>
- [4] Genesis Authors, “Genesis: A generative and universal physics engine for robotics and beyond,” *GitHub repository*, Dec. 2024. [Online]. Available: <https://github.com/Genesis-Embodied-AI/Genesis>
- [5] J. Gillick, “Genesis forge: A modular framework for rl robot environments,” *GitHub repository*, Sep. 2025. [Online]. Available: <https://github.com/jgillick/genesis-forge>
- [6] A. Miki, J. Lee, L. Wellhausen, V. Koltun, and M. Hutter, “Learning robust perceptive locomotion for legged robots in the wild,” *Science Robotics*, vol. 7, no. 62, p. eabk2822, 2022.
- [7] H. Shi *et al.*, “Learning bipedal locomotion on gear-driven humanoid robot using foot-mounted IMUs,” 2025.
- [8] D. Kim, H. Lee, J. Cha, and J. Park, “Bridging the reality gap: Analyzing sim-to-real transfer techniques for reinforcement learning in humanoid bipedal locomotion,” *IEEE Robotics & Automation Magazine*, vol. 32, no. 1, p. 49, 2025.
- [9] A. Kumar, Z. Fu, D. Pathak, and J. Malik, “RMA: Rapid motor adaptation for legged robots,” 2021.
- [10] Z. Li *et al.*, “Learn to teach: Sample-efficient privileged learning for humanoid locomotion over real-world uneven terrain,” *IEEE Robotics and Automation Letters*, vol. 10, no. 9, pp. 9048–9055, Sep. 2025.